

# Laboratorijska vježba 4 - Statističko zaključivanje dvije varijable - linearna regresija

Metode statističke analize podataka

2025./2026.

## Cilj zadatka

Primijeniti metode statističke analize podataka na datasetu `AirQualityUCI.csv` kako biste:

- učitali i očistili relevantne varijable,
- izgradili i analizirali jedan linearni regresijski model,
- procijenili parametre modela, intervale povjerenja i adekvatnost modela,
- izračunali koeficijent korelacije između odabranih varijabli i interpretirali rezultate.

**Dataset:** Koristite dataset `AirQualityUCI.csv` koji sadrži mjerenja kvalitete zraka u gradu (koncentracije plinova, temperaturne i vlažne uvjete, itd.). Primjeri varijabli:

- `CO (GT)` – koncentracija ugljičnog monoksida ( $\text{mg/m}^3$ ),
- `NO2 (GT)` – koncentracija dušikova dioksida ( $\mu\text{g/m}^3$ ),
- `C6H6 (GT)` – benzene ( $\mu\text{g/m}^3$ ),
- `T` – temperatura ( $^{\circ}\text{C}$ ),
- `RH` – relativna vlažnost (%),
- `AH` – apsolutna vlažnost.

## Koraci za rješavanje zadatka

### 1. Učitavanje i pregled podataka

- a) Učitajte dataset u Python (npr. `pandas.read_csv("AirQualityUCI.csv")`).
- b) Ispišite nekoliko prvih redaka tablice i ispitajte strukturu podataka:
  - struktura: `data.info()`,
  - osnovne statistike: `data.describe()`,
  - tipovi podataka: `data.dtypes`.

- c) Provjerite nedostajuće vrijednosti i posebne kodove nedostajućih vrijednosti:
- `data.isna().sum()`,
  - obratite pozornost na vrijednosti  $-200$  koje u ovom datasetu označavaju nedostajuće mjere određenih senzora.
- d) Očistite podatke:
- zamijenite vrijednosti  $-200$  sa `NaN`,
  - uklonite retke s `NaN` *za dvije varijable koje ćete koristiti u regresijskom modelu.*
- e) Kratko komentirajte odabir načina čišćenja (zadržati, odbaciti, zamijeniti).

## 2. Definiranje hipoteza i odabir varijabli za regresiju

- a) Odaberite jednu zavisnu varijablu  $Y$  i jednu nezavisnu varijablu  $X$  za koju pretpostavljate linearnu vezu.
- b) Zapišite model:
- $$Y = \beta_0 + \beta_1 X + \varepsilon.$$
- c) Za svaki model odaberite:
- ciljnu varijablu  $Y$  (npr. `NO2 (GT)` ili `CO (GT)`),
  - jednu nezavisnu varijablu  $X$  za koju pretpostavljate linearnu vezu s  $Y$  (npr. `C6H6 (GT)`, `T`, `RH`, ...).
- d) Zapišite hipoteze:
- $H_0 : \beta_1 = 0$  (nema linearne veze između  $X$  i  $Y$ ),
  - $H_1 : \beta_1 \neq 0$  (postoji linearna veza).

## 3. Izgradnja linearnog regresijskog modela

- a) Procijenite parametre modela:
- `scipy.stats.linregress(X, Y)` i/ili
  - `statsmodels.OLS`.
  - ako su skale vrlo različite (npr. koncentracija plina vs. temperatura), po potrebi standardizirajte ili skalirajte varijable (npr. `StandardScaler` iz `sklearn`).
- b) Prikažite regresijski model na dijagramu raspršenja (scatter + regresijska linija).
- c) Pazite na ispravno obilježavanje osi (nazivi varijabli i jedinice).
- d) Izračunajte i interpretirajte:
- nagib  $\hat{\beta}_1$ ,
  - odsječak  $\hat{\beta}_0$ ,
  - koeficijent determinacije  $R^2$ .

## 4. Intervali povjerenja za parametre

- a) Izračunajte 95% intervale povjerenja za  $\beta_0$  i  $\beta_1$ .

- b) Možete koristiti:
- rezultate iz `statsmodels(results.conf_int())`,
  - ili ručni izračun pomoću standardne pogreške i kritične vrijednosti  $t$ -distribucije.
- c) Protumačite uključuje li interval za  $\beta_1$  nulu i što to znači.

## 5. Analiza adekvatnosti modela

- a) Izračunajte rezidualne i grafički ih prikazite:
- reziduali naspram predviđenih vrijednosti,
  - histogram reziduala.
- b) Analizirajte rezidualne kako biste procijenili je li linearni model primjeren:
- nacrtajte graf *reziduali naspram predviđenih vrijednosti*,
  - komentirajte: postoji li vidljiv uzorak? (trend, zakrivljenost, oblik lijevka ...),
  - procijenite postoji li heteroskedastičnost (nejednaka varijanca reziduala).
- c) Provjerite normalnost reziduala:
- histogram reziduala,
  - QQ-plot,
  - kratka interpretacija koliko odstupaju od normalne razdiobe.
- d) Komentirajte homoskedastičnost:
- jesu li reziduali otprilike jednako raspršeni oko 0 za sve predviđene vrijednosti?
- e) Još jednom izračunajte i interpretirajte  $R^2$  kao mjeru kvalitete modela:
- koliko varijance zavisne varijable je objašnjeno modelom,
  - je li takav  $R^2$  u ovom kontekstu zadovoljavajući?

## 6. Koeficijent korelacije

- a) Izračunajte Pearsonov koeficijent korelacije između ciljane i nezavisne varijable za svaki model.
- b) Interpretirajte:
- smjer povezanosti (pozitivan/negativan),
  - jačinu povezanosti (slaba/umjerena/snažna),
  - povezanost s  $R^2$  (za jednostavnu linearnu regresiju vrijedi  $R^2 = r^2$ ).

## 7. Testiranje adekvatnosti modela – F-test

- a) U okviru jednostavne linearne regresije potrebno je provesti F-test kako bi se ispitalo ima li regresijski model uopće objašnjavačku moć (odnosno je li barem jedan regresijski koeficijent različit od nule).
- b) Izračunajte F-statistiku i pripadnu p-vrijednost (npr. iz `statsmodels.summary()`).
- c) Interpretirajte rezultate:
- za odabranu razinu značajnosti  $\alpha$  (npr. 0.05), odlučite odbacujete li nul-hipotezu da model nema objašnjavačku moć,

- objasnite u kontekstu problema (predviđanje kvalitete zraka).

## 8. Zaključak

a) Sažmite najvažnije rezultate analize:

- značajnost  $\beta_1$ ,
- jačina veze,
- adekvatnost modela prema rezidualima i F-testu.

## 9. Deskriptivna statistika (opcionalno)

a) Odaberite **četiri** kvantitativne varijable (npr. CO (GT) , NO<sub>2</sub> (GT) , T, RH) i izračunajte:

- apsolutne srednje vrijednosti, standardne devijacije,
- relativne mjere (npr. koeficijent varijacije) uz kratku interpretaciju.

b) Vizualizirajte odabrane varijable:

- histogrami,
- box-plotovi,
- dijagrami raspršenja za parove varijabli za koje očekujete povezanost (npr. NO<sub>2</sub> (GT) –C<sub>6</sub>H<sub>6</sub> (GT) , T–RH).

c) Napišite kratku interpretaciju:

- Varijabilnost:** Koji od odabranih parametara imaju najveću varijabilnost (relativno na njihovu srednju vrijednost)?
- Iznimne vrijednosti:** Postoje li iznimno visoke ili niske vrijednosti (outlieri) koje su ostale u datasetu nakon čišćenja?
- Obrazloženje odabira:** Objasnite zašto ste odabrali baš te četiri varijable za analizu (npr. važnost za kvalitetu zraka, logična fizička povezanost).