

Laboratorijska vježba 5 - Nelinearna jednostavna regresija i višestruka regresija

Metode statističke analize podataka

2025./2026.

1 Cilj vježbe

Cilj ove laboratorijske vježbe je upoznati se s:

- nelinearnom jednostavnom regresijom na primjeru **logističke regresije** (binarni ishod),
- **višedimenzionalnom linearnom regresijom** (više regresora),
- osnovnim pretpostavkama, interpretacijom koeficijenata i osnovnim dijagnostičkim mjerama modela.

Studenti nakon vježbe trebaju:

- znati prepoznati situacije kada linearna regresija nije primjeren model za zavisnu varijablu,
- razumjeti zašto koristimo logističku funkciju (sigmoid) za modeliranje vjerojatnosti,
- moći zapisati i interpretirati model višestruke linearne regresije,
- poznavati ulogu koeficijenta determinacije R^2 , prilagođenog R^2 i F-testa,
- biti svjesni problema multikolinearnosti i pojma VIF (Variance Inflation Factor).

2 Nelinearna jednostavna regresija: logistička regresija

2.1 Motivacija

Kod klasične jednostavne linearne regresije pretpostavljamo model oblika

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

gdje je Y kvantitativna (numerička) zavisna varijabla.

Međutim, u mnogim primjenama zavisna varijabla je **binarna**, npr.:

- uspjeh / neuspjeh (1 / 0),
- kupio proizvod / nije kupio,
- bolestan / zdrav,
- klik na oglas / nema klika.

U takvim slučajevima:

- Y poprima samo vrijednosti 0 ili 1,
- zanima nas **vjerojatnost** da se događaj dogodi, tj. $P(Y = 1 | X)$,
- linearnim modelom $\beta_0 + \beta_1 X$ ne možemo direktno modelirati vjerojatnost, jer vrijednosti mogu biti manje od 0 ili veće od 1.

Zato uvodimo **logističku regresiju** kao nelinearni model: transformiramo linearni izraz

$$z = \beta_0 + \beta_1 X$$

logističkom (sigmoidnom) funkcijom u interval $(0, 1)$.

2.2 Logistička funkcija i definicija modela

Logistička funkcija (sigmoid) ili logaritam omjera šansi (engl. *log-odds*) definirana je kao

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Za svaku realnu vrijednost $z \in \mathbb{R}$ vrijedi:

$$0 < \sigma(z) < 1, \quad \lim_{z \rightarrow -\infty} \sigma(z) = 0, \quad \lim_{z \rightarrow +\infty} \sigma(z) = 1.$$

Model logističke regresije za binarnu zavisnu varijablu $Y \in \{0, 1\}$ i jednu nezavisnu varijablu X zapisujemo kao

$$P(Y = 1 | X) = \pi(X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}. \quad (1)$$

Gdje su:

- $P(Y = 1 | X)$ – vjerojatnost da se događa “pozitivni” ishod (npr. uspjeh, bolest prisutna, kupnja proizvoda),
- β_0 – presjek (intercept),
- β_1 – koeficijent koji opisuje utjecaj X na logit vjerojatnosti.

2.3 Logit, izgledi i linearizacija modela

Umjesto da izravno modeliramo vjerojatnost $\pi(X)$, često radimo s tzv. **izgledima** (odds):

$$\text{odds}(X) = \frac{\pi(X)}{1 - \pi(X)}.$$

Ako u logistički model uvrstimo definiciju $\pi(X)$ (Eq. 1), dobivamo:

$$\frac{\pi(X)}{1 - \pi(X)} = e^{\beta_0 + \beta_1 X}.$$

Logit funkcija je logaritam izgleda:

$$\text{logit}(\pi(X)) = \log\left(\frac{\pi(X)}{1 - \pi(X)}\right).$$

U logističkoj regresiji logit je **linearna funkcija** od X :

$$\log\left(\frac{\pi(X)}{1 - \pi(X)}\right) = \beta_0 + \beta_1 X.$$

Ovim smo postigli:

- na razini vjerojatnosti model je nelinearan (sigmoid),
- na razini logita model je **linearan** u parametrima β_0, β_1 .

2.4 Interpretacija parametara u logističkoj regresiji

Presjek β_0 . Kada je $X = 0$, logit vjerojatnosti je jednak β_0 :

$$\log\left(\frac{\pi(0)}{1 - \pi(0)}\right) = \beta_0.$$

To znači da β_0 predstavlja log-izglede za ishod $Y = 1$ kada je $X = 0$. U praksi $X = 0$ ponekad nema smisla (npr. dob = 0 godina), ali je nužan za određivanje položaja sigmoidne krivulje.

Koeficijent β_1 . Koeficijent β_1 opisuje promjenu log-izgleda pri promjeni X za jednu jedinicu:

$$\log\left(\frac{\pi(X+1)}{1 - \pi(X+1)}\right) - \log\left(\frac{\pi(X)}{1 - \pi(X)}\right) = \beta_1.$$

Primjenom eksponencijalne funkcije na obje strane jednadžbe, dobivamo omjer:

$$\frac{\text{odds}(X+1)}{\text{odds}(X)} = e^{\beta_1}. \quad (2)$$

Dakle:

- ako je $\beta_1 > 0$, tada $e^{\beta_1} > 1$ i izgledi za $Y = 1$ rastu s povećanjem X ,
- ako je $\beta_1 < 0$, tada $e^{\beta_1} < 1$ i izgledi za $Y = 1$ padaju s povećanjem X ,
- ako je $\beta_1 = 0$, tada $e^{\beta_1} = 1$ i X nema utjecaja na vjerojatnost ishoda.

2.5 Procjena parametara: metoda maksimalne vjerodostojnosti

Za razliku od linearne regresije (gdje se parametri obično procjenjuju metodom najmanjih kvadrata), u logističkoj regresiji koristimo **metodu maksimalne vjerodostojnosti** (engl. Maximum Likelihood Estimation, MLE).

Ideja:

- pretpostavimo da su opažanja (x_i, y_i) nezavisna,
- za svaki par vrijedi

$$P(Y_i = 1 \mid X_i) = \pi_i, \quad P(Y_i = 0 \mid X_i) = 1 - \pi_i,$$

gdje je

$$\pi_i = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_i)}}.$$

- funkcija vjerodostojnosti je umnožak vjerojatnosti za sve opažene ishode:

$$L(\beta_0, \beta_1) = \prod_{i=1}^n \pi_i^{y_i} (1 - \pi_i)^{1-y_i},$$

- tražimo vrijednosti β_0, β_1 koje **maksimiziraju** $L(\beta_0, \beta_1)$, odnosno log-vjerodostojnost

$$\ell(\beta_0, \beta_1) = \log L(\beta_0, \beta_1).$$

Analitičko zatvoreno rješenje u pravilu ne postoji, pa se u računalnim paketima koriste **numeričke optimizacijske metode** (npr. Newton–Raphson, iterativna regresija težina i sl.).

2.6 Zašto ne koristiti običnu linearnu regresiju za binarnu Y ?

Ako bismo za binarni ishod pokušali koristiti model

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

dobili bismo sljedeće probleme:

- predviđene vrijednosti \hat{Y} ne bi bile ograničene na interval $[0, 1]$, nego bi mogle biti npr. $-0,3$ ili $1,4$,
- varijanca pogreške nije konstantna (varijanca Bernoullijeve varijable ovisi o π),
- pretpostavke linearne regresije (normalnost reziduala, homoskedastičnost) teško su zadovoljene.

Logistička regresija:

- daje predviđene vjerojatnosti u intervalu $(0, 1)$,
- bolje odražava prirodu binarne zavisne varijable,
- ima jasnu interpretaciju u terminima izgleda (odds) i logita.

Razmotrimo jednostavan primjer u kojem želimo modelirati vjerojatnost da će student položiti ispit ($Y = 1$) na temelju vremena provedenog u učenju (X). Pretpostavimo da su opažanja sljedeća:

Sati učenja X	Ishod Y
1	0
2	0
3	0
4	1
5	1
6	1

Želimo procijeniti logistički model:

$$P(Y = 1 | X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}.$$

Numeričko rješenje (pojednostavljeno)

Pretpostavimo da metoda maksimalne vjerodostojnosti daje sljedeće procjene:

$$\hat{\beta}_0 = -6.5, \quad \hat{\beta}_1 = 1.3.$$

Model postaje:

$$\hat{P}(Y = 1 | X) = \frac{1}{1 + e^{-(-6.5 + 1.3X)}}.$$

Izračunajmo procijenjene vjerojatnosti za nekoliko vrijednosti:

$$\hat{P}(Y = 1 | X = 3) = \frac{1}{1 + e^{-(-6.5 + 3.9)}} = \frac{1}{1 + e^{2.6}} \approx 0.069.$$

$$\hat{P}(Y = 1 | X = 5) = \frac{1}{1 + e^{-(-6.5 + 6.5)}} = \frac{1}{1 + e^0} = 0.5.$$

$$\hat{P}(Y = 1 | X = 6) = \frac{1}{1 + e^{-(-6.5 + 7.8)}} = \frac{1}{1 + e^{-1.3}} \approx 0.785.$$

Interpretacija

- Nakon oko 5 sati učenja vjerojatnost prolaza ispita iznosi oko 0.5.
- Za svaki dodatni sat učenja, log-izgledi se povećavaju za $\hat{\beta}_1 = 1.3$.
- Budući da je $e^{1.3} \approx 3.67$, izgledi prolaska *povećavaju se 3.67 puta* za svaki dodatni sat učenja.

U nastavku slijedi primjer prilagodbe logističkog modela u Pythonu koristeći paket `statsmodels`.

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

# Podaci
X = np.array([1, 2, 3, 4, 5, 6])
y = np.array([0, 0, 0, 1, 1, 1])

df = pd.DataFrame({"Hours": X, "Pass": y})

# Dodati konstantu
X_sm = sm.add_constant(df["Hours"])

# Logistički model
model = sm.Logit(df["Pass"], X_sm).fit()
print(model.summary())

# Predviđanje vjerojatnosti
x_new = pd.DataFrame({"const": 1, "Hours": [3, 5, 6]})
pred_probs = model.predict(x_new)

print("Predviđene vjerojatnosti:")
print(pred_probs)
```

Očekivani ispis

Model će procijeniti koeficijente β_0 i β_1 te dati:

- procijenjene parametre,
- standardne pogreške,
- z-statistike i p-vrijednosti,
- pseudo R^2 ,
- predviđene vjerojatnosti za nove podatke.

Tipični rezultat predviđanja

Primjer ispisa:

```
X = 3 → P(Y=1) = 0.07
X = 5 → P(Y=1) = 0.50
X = 6 → P(Y=1) = 0.79
```

Što se poklapa s našim numeričkim primjerom.

5.1 Motivacija i definicija modela

U jednostavnoj linearnoj regresiji imamo:

$$Y = \beta_0 + \beta_1 X + \varepsilon.$$

U praksi, Y vrlo često ovisi o više od jedne nezavisne varijable. Primjeri:

- potrošnja goriva vozila ovisi o masi, snazi motora, vrsti prijenosa, zapremini motora,
- jačina povlačenja žice ovisi o duljini žice i visini čipa,
- vrijeme izvršavanja algoritma o veličini ulaza i broju dretvi (threadova).

Tada modeliramo:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon.$$

Gdje je:

- Y – zavisna (odgovorna) varijabla,
- X_1, \dots, X_k – nezavisne (prediktorske) varijable,
- β_0 – presjek (intercept),
- β_j – koeficijent povezan s varijablom X_j ,
- ε – slučajna pogreška (neobjašnjena varijabilnost).

5.2 Matrični zapis modela

Za n opažanja možemo model zapisati u matričnom obliku:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

gdje je:

- \mathbf{y} vektor dimenzije $n \times 1$ (opažanja Y_i),
- \mathbf{X} matrica dimenzije $n \times p$ ($p = k + 1$), gdje prvi stupac sadrži jedinice (za β_0), a preostali stupci vrijednosti regresora X_1, \dots, X_k :

$$\mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{bmatrix},$$

- β vektor parametara dimenzije $p \times 1$:

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix},$$

- ε vektor pogrešaka dimenzije $n \times 1$.

5.3 Pretpostavke modela višestruke linearne regresije

Standardne pretpostavke su:

1. **Linearnost:** očekivana vrijednost $E(Y \mid X_1, \dots, X_k)$ linearna je funkcija regresora:

$$E(Y \mid X_1, \dots, X_k) = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k.$$

2. **Nezavisnost pogrešaka:** pogreške ε_i su međusobno nezavisne.
3. **Jednakost varijanci (homoskedastičnost):** $Var(\varepsilon_i) = \sigma^2$ za sve i .
4. **Normalnost pogrešaka:** $\varepsilon_i \sim N(0, \sigma^2)$.
5. **Nema jake multikolinearnosti:** regresori nisu gotovo linearno zavisni (npr. nema gotovo savršene korelacije između X_1 i X_2).

Te pretpostavke se u praksi provjeravaju analizom reziduala, grafovima i dodatnim testovima.

5.4 Procjena parametara metodom najmanjih kvadrata

Procjenitelj metode najmanjih kvadrata minimizira sumu kvadrata reziduala:

$$S(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_k x_{ik})^2.$$

U matričnom obliku:

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta).$$

Minimizacijom po β dobivamo normalne jednačbe, a rješenje (ako $\mathbf{X}^T \mathbf{X}$ ima inverz):

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.$$

Procjene $\hat{\beta}_j$ zatim interpretiramo kao:

- $\hat{\beta}_0$ – očekivana vrijednost Y kada su svi regresori jednaki nuli (često samo tehnički parametar),
- $\hat{\beta}_j$ za $j \geq 1$ – promjena u očekivanoj vrijednosti Y kada X_j poraste za jednu jedinicu, uz **fiksne** ostale regresore.

5.5 Dekompozicija sume kvadrata i koeficijent determinacije

Ukupnu varijabilnost Y možemo rastaviti na:

$$SST = SSR + SSE,$$

gdje je:

- SST – totalna suma kvadrata (total sum of squares),
- SSR – suma kvadrata regresije (sum of squares due to regression),
- SSE – suma kvadrata pogreške (sum of squares for error / residual).

Koeficijent determinacije je definiran kao:

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}.$$

On mjeri koji dio varijabilnosti zavisne varijable Y je objašnjen modelom (regresorima):

- R^2 je u intervalu $[0, 1]$,
- veća vrijednost znači da model bolje prilagođava podatke,
- međutim, R^2 **uvijek raste** dodavanjem novih regresora, čak i ako oni nisu stvarno važni.

Zato koristimo i **prilagođeni koeficijent determinacije**:

$$R_{\text{adj}}^2 = 1 - \frac{SSE/(n-p)}{SST/(n-1)},$$

gdje je p broj parametara (uključujući presjek). Prilagođeni R^2 kažnjava dodavanje irelevantnih regresora.

5.6 Testiranje značajnosti modela: F-test

Želimo testirati hipotezu:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$$

(odnosno model nema objašnjavačku moć, jedini parametar je presjek) protiv

$$H_1 : \text{barem jedan od } \beta_j \text{ je različit od nule.}$$

Test statistika:

$$F_0 = \frac{SSR/k}{SSE/(n-p)}.$$

Ako su zadovoljene pretpostavke modela, F_0 slijedi F -razdiobu s k i $n-p$ stupnjeva slobode pod H_0 .

- Ako je p -vrijednost $\leq \alpha$ (npr. $\alpha = 0,05$), odbacujemo H_0 i zaključujemo da model kao cjelina ima objašnjavačku moć.
- Ako je p -vrijednost $> \alpha$, nemamo dovoljno dokaza da model objašnjava Y bolje od modela samo s presjekom.

5.7 Testiranje pojedinačnih koeficijenata: t-test

Za svaki koeficijent β_j (obično $j = 1, \dots, k$) testiramo:

$$H_0 : \beta_j = 0, \quad H_1 : \beta_j \neq 0.$$

Test statistika ima oblik:

$$t_0 = \frac{\hat{\beta}_j}{se(\hat{\beta}_j)},$$

gdje je $se(\hat{\beta}_j)$ procijenjena standardna pogreška koeficijenta $\hat{\beta}_j$.

Pod H_0 , uz pretpostavke modela, t_0 slijedi t -razdiobu s $n - p$ stupnjeva slobode. Na temelju p -vrijednosti zaključujemo je li pojedini regresor statistički značajan uz ostale u modelu.

5.8 Dva načina implementacije višestruke linearne regresije u Pythonu

Višestruka linearna regresija matematički se zapisuje kao:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon,$$

što se u statističkoj notaciji često prikazuje putem formule:

$$Y \sim X_1 + X_2 + X_3.$$

U Pythonu (biblioteka `statsmodels`) postoje **dva standardna načina** izgradnje takvog modela.

5.8.1 Formula API ($Y \sim X_1 + X_2 + X_3$)

Ovaj pristup automatski:

- kreira matricu prediktora X ,
- dodaje konstantu,
- prepoznaje dummy varijable prema nazivima stupaca.

```
1 import statsmodels.formula.api as smf
2
3 model = smf.ols("Y~X1+X2+X3", data=df).fit()
4 print(model.summary())
```

5.8.2 Klasični OLS zapis (`sm.OLS(y, X)`)

U ovom pristupu korisnik ručno definira matricu prediktora X i mora eksplicitno dodati konstantu.

```

1 import statsmodels.api as sm
2
3 y = df["Y"]
4 X = df[["X1", "X2", "X3"]]
5 X_const = sm.add_constant(X)
6
7 model = sm.OLS(y, X_const).fit()
8 print(model.summary())

```

Razlika između dva pristupa

- **Formula API** koristi zapis nalik na R-u (npr. $Y \sim X1+X2$) i automatski obavlja pripremu podataka. Idealan je za brzu specifikaciju modela i lakše čitanje koda.
- **Čisti OLS pristup** zahtijeva ručno konstruiranje matrice X , uključujući dodavanje konstante. Daje veću fleksibilnost i veću kontrolu nad konstrukcijom modela (npr. kada se koriste skalirane, transformirane ili ručno kreirane značajke).
- Statistički i numerički modeli dobiveni jednim i drugim pristupom **identični su** — razlika je isključivo u načinu specificiranja modela.

5.9 Koeficijent determinacije

Koeficijent determinacije definiran je kao omjer sume kvadrata objašnjenog dijela i ukupne sume kvadrata, te poprima vrijednosti na intervalu $[0, 1]$. Koristi se kao deskriptivno obilježje snage linearnog odnosa između nezavisnih varijabli i zavisne varijable, te kao kriterij usporedbe modela na istim uzorcima.

Kvalitetni modeli imaju R^2 vrijednost blizu 1.

5.10 Skaliranje podataka

Skaliranje podataka prilagođava vrijednosti varijabli na određeni raspon, najčešće $[0, 1]$ ili $[-1, 1]$. Korisno je za modele osjetljive na skalu varijabli (k-NN, SVM, neuronske mreže).

Standardizacija podrazumijeva transformaciju varijabli na sredinu 0 i standardnu devijaciju 1. Potrebna je kada varijable imaju različite skale i kada želimo stabilnije koeficijente u regresijskom modelu.

Kod jednostavne linearne regresije oblika:

$$y = \beta_0 + \beta_1 x,$$

standardizacija nije nužna.

Interpretacija bez standardizacije zadržava mjerne jedinice, što olakšava tumačenje parametara.

Prednosti:

- koeficijenti β_0 i β_1 imaju stvarno značenje u kontekstu problema;
- podaci zadržavaju svoje mjerne jedinice

Ograničenja:

- ako x i y imaju vrlo različite skale, može nastati numerička nestabilnost.

Standardizacija je korisna:

- za usporedbu prediktora u višestrukoj regresiji (dob, prihod, razina obrazovanja)
 - standardizacija omogućuje lakše uspoređivanje njihovog relativnog utjecaja jer svi prediktori imaju istu skalu (srednja vrijednost 0, standardna devijacija 1)
- kada se koriste različiti skupovi podataka,
- kod optimizacijskih metoda (npr. gradijentni spust - standardizacija može poboljšati stabilnost i brzinu konverencije algoritma).

5.11 Kako standardizirati

Biblioteka scikit-learn sadrži klase:

(a) StandardScaler Standardizacija ili normalizacija z-vrijednosti, transformira podatke tako da im je ar.sredina jednaka nula i standardna devijacija 1. Ova metoda je korisna kada varijable imaju različite skale i mjerne jedinice.

```
1 from sklearn.preprocessing import StandardScaler
2
3 scaler = StandardScaler()
4 scaled_data = scaler.fit_transform(data)
```

(b) MinMaxScaler Normalizacija ili skaliranje podataka na fiksni raspon, obično između 0 i 1. Ova tehnika je korisna kada varijable imaju različite raspone i želi se sačuvati izvorna distribucija podataka.

```
1 from sklearn.preprocessing import MinMaxScaler
2
3 scaler = MinMaxScaler()
4 scaled_data = scaler.fit_transform(data)
```

(c) RobustScaler Normalizacija medijana i kvantila, mjeri podatke na temelju robustnih procjena lokacije i razmjera. Ova metoda je korisna kada podaci sadrže ekstremne vrijednosti (otporan na outliere) ili kada distribucija ne prati Gaussovu razdiobu.

```
1 from sklearn.preprocessing import RobustScaler
2
3 scaler = RobustScaler()
4 scaled_data = scaler.fit_transform(data)
```

Napomena: Više o ovome možete pronaći na [linku](#).

5.12 Pretvaranje kategorijskih značajki u numeričke

Najčešće se koriste dvije metode: **Label Encoding** i **One-Hot Encoding**, ali se moram paziti kada se koja koristi.

5.12.1 Label Encoding

Kodiranje oznakama - pretvara svaku kategoriju u jedinstveni cijeli broj, ali ako ima više kategorija, onda uvodi "redoslijed" među kategorijama, što nije prikladno u većini slučajeva s više kategorija.

```
1 from sklearn.preprocessing import LabelEncoder
2
3 label_encoder = LabelEncoder()
4 df["mainroad"] = label_encoder.fit_transform(df["mainroad"])
```

5.12.2 One-Hot Encoding

Koristi se kod varijabli koje imaju više kategorija. Ova metoda stvara novi binarni stupac za svaku kategoriju.

Prednosti: Uklanja problem "redoslijeda" među kategorijama; prikladno za značajke s više kategorija. Nedostaci: Može stvoriti veliki broj novih kolona, što povećava dimenzionalnost podataka.

Primjer 5.1. Pretpostavimo da imamo dataset s kategorijskom značajkom City koja ima tri različite vrijednosti: London, Paris, i Berlin.

```
1 import pandas as pd
2
3 data = {"City": ["London", "Paris", "Berlin", "London", "Berlin"]}
4 df = pd.DataFrame(data)
5
6 df_encoded = pd.get_dummies(df, columns=["City"], drop_first=False)
7 print(df_encoded)
```

Koristimo `pd.get_dummies()` za pretvaranje kategorijskih vrijednosti u binarne stupce.

Objašnjenje rezultata: Svaka jedinstvena vrijednost u značajki City postaje zaseban stupac.

Vrijednosti u stupcima su:

1 ako redak pripada toj kategoriji.

0 inače.

Uklanjanje prvog stupca (`drop_first=True`): Da biste izbjegli višestruku kolinearnost (redundantne informacije), možete ukloniti jedan stupac koristeći

`drop_first=True`.

```
1 df_encoded = pd.get_dummies(df, columns=["City"], drop_first=True)
2
3 print("\nPodaci s uklonjenom prvom kategorijom:")
4 print(df_encoded)
```

Berlin nije obrisan, već je implicitno predstavljen kao "osnovna kategorija". To znači da kada su sve ostale kategorije (`City_London` i `City_Paris`) 0, tada znamo da je pripadajuća kategorija `Berlin`.

Ovo je poznato kao referentna kategorija i koristi se za izbjegavanje višestruke kolinearnosti u regresijskim modelima. Kada koristimo `drop_first=True`, uklanjamo jednu kategoriju (u ovom slučaju, `City_Berlin`) i time smanjujemo redundantnost podataka.

5.12.3 Binary_map za binarne kategorijske značajke

Za pretvaranje binarnih kategorijskih značajki u numeričke (0 i 1) može se koristiti i funkcija `binary_map()`, što predstavlja brži i jednostavniji pristup od One-Hot Encodinga kada se radi o dvjema kategorijama.

- **Jednostavnost:**

- Ako je kategorijska značajka već binarna (npr. `yes/no`, `true/false`, `male/female`), `binary_map()` izravno mapira vrijednosti na brojeve:
 - * `yes` → 1, `no` → 0
 - * `True` → 1, `False` → 0
 - * `Male` → 1, `Female` → 0

- **Brzina i efikasnost:**

- Kod binarnih značajki nije potrebno stvarati nove stupce kao kod One-Hot Encodinga.
- Mapiranje se izvodi izravno nad postojećim stupcem, što smanjuje memorijsku potrošnju i ubrzava obradu.

- **Lakša interpretacija:**

- Rezultirajuća vrijednost je intuitivna: 1 predstavlja jednu kategoriju, a 0 drugu.

- **Implementacija:**

- Najčešće se implementira kao prilagođena Python funkcija koja koristi metode `map()` ili `replace()`, primjerice:

```
def binary_map(feature):  
    return feature.map({"yes": 1, "no": 0})
```

Za binarne značajke (`yes/no`, `male/female`):

```
1 def binary_map(feature):  
2     return feature.map({"yes": 1, "no": 0})  
3  
4 df["mainroad"] = binary_map(df["mainroad"])
```

ili:

```
1 df["mainroad"] = df["mainroad"].replace({"yes": 1, "no": 0})
```

Za True/False:

```
1 housing["semi-furnished"] = housing["semi-furnished"].map(  
2 {True: 1, False: 0}  
3 )
```

Kada NE koristiti:

- **One-Hot Encoding** — nepotrebno za binarne varijable,
- **Label Encoding** — uvodi umjetni poredak.

5.13 Multikolinearnost

Variance Inflation Factor (VIF) kvantificira multikolinearnost među prediktorima.

Što je multikolinearnost?

Multikolinearnost nastaje kada su dvije ili više nezavisnih varijabli u regresijskom modelu **međusobno snažno povezane**.

Posljedice:

- koeficijenti postaju numerički nestabilni (male promjene u podacima mogu uzrokovati velike promjene u procijenjenim koeficijentima),
- standardne pogreške koeficijenata rastu,
- t-testovi za pojedine koeficijente mogu pokazivati neznačajnost iako model kao cjelina ima dobru objašnjavačku moć,
- teško je odvojiti utjecaj pojedinih prediktora.

Variance Inflation Factor (VIF)

VIF kvantificira razinu multikolinearnosti za svaku varijablu X_i :

Formula:

$$VIF_i = \frac{1}{1 - R_i^2} \quad (3)$$

gdje je R_i^2 koeficijent determinacije dobiven regresijom varijable X_i na sve ostale prediktore.

Interpretacija

- VIF = 1: nema multikolinearnosti,
- VIF > 5: visoka multikolinearnost,
- VIF > 10: ekstremna multikolinearnost.

Primjer 5.2.

```
1 from statsmodels.stats.outliers_influence import
   variance_inflation_factor
2
3 data["Gender"] = data["Gender"].map({"Male": 0, "Female"
   : 1})
4 X = data[["Gender", "Height", "Weight"]]
5
6 vif_data = pd.DataFrame()
7 vif_data["feature"] = X.columns
8 vif_data["VIF"] = [
9     variance_inflation_factor(X.values, i)
10     for i in range(len(X.columns))
11 ]
12 print(vif_data)
```

Napomena: više na [linku](#).

6

Zadaci za pripremu

Opis vježbe

U ovoj pripremi za laboratorijsku vježbu koristiti skup podataka *Airlines Customer Satisfaction* (korisnička zadovoljstva u zračnom prijevozu).

Ciljevi pripreme za vježbu su:

- upoznati se s osnovama rada s kategorijskim i numeričkim varijablama u Pandas DataFrameu,
- izračunati i interpretirati koeficijente korelacije između numeričkih varijabli,
- izgraditi **logistički regresijski model** za predikciju **zadovoljstva putnika**,
- interpretirati koeficijente logističke regresije (znak, veličina, odds ratio),
- izgraditi višestruku regresiju

Opis skupa podataka

Skup podataka sadrži zapise o putnicima i njihovim ocjenama usluge. Neke od varijabli su:

- Gender – spol putnika (Male/Female),
- Customer Type – tip putnika (Loyal customer / disloyal),
- Age – dob putnika,
- Type of Travel – vrsta putovanja (Business / Personal),
- Class – klasa putovanja (Business, Eco, Eco Plus),
- Flight Distance – udaljenost leta,

- niz ocjena usluge (skala 1–5): Seat comfort, Food and drink, Inflight wifi service, Inflight entertainment, On-board service, Cleanliness, Baggage handling, Leg room service,...
- Departure Delay in Minutes, Arrival Delay in Minutes,
- Satisfaction – ciljna varijabla (Satisfied / dissatisfied).

6.1 Zadatak: Učitavanje i osnovno čišćenje podataka

1. Uvezite potrebne biblioteke (pandas, numpy, matplotlib, seaborn, statsmodels, sklearn po potrebi).
2. Učitajte CSV datoteku s podacima, npr.:

```
import pandas as pd
df = pd.read_csv("Naziv_dokumenta.csv")
```

3. Ispitajte osnovne informacije o DataFrameu:

```
df.info()
df.describe()
```

4. Provjerite nedostajuće vrijednosti i po potrebi ih uklonite ili zamijenite:

```
df.isna().sum()
df = df.dropna()
```

6.2 Zadatak: Priprema varijabli za analizu

1. Kreirajte binarnu varijablu zadovoljstva, jer ima samo dvije vrijednosti:

```
df["Satisfied"] = df["satisfaction"].map({
    "jedna_kategorija": 1,
    "druga_kategorija": 0
})
```

Provjeriti je li dobro kategorizirano.

```
df["Satisfied"].unique()
```

Ako je sve u redu, onda rješenje treba izgledati: `array([1, 0])`

Možete provjeriti i s:

```
df["Satisfied"].value_counts()
```

2. Odaberite skup numeričkih varijabli za analizu korelacije, npr.:

- Age,
- Flight Distance,
- Seat comfort,
- Inflight entertainment,
- On-board service,
- Cleanliness,
- Departure Delay in Minutes,
- Arrival Delay in Minutes.

```
num_cols = ["Age", "Flight Distance",  
            "Seat comfort", "Inflight entertainment",  
            "On-board service", "Cleanliness",  
            "Departure Delay in Minutes",  
            "Arrival Delay in Minutes",  
            "Satisfied"]  
df_num = df[num_cols]
```

6.3 Zadatak: Odabir prikladnog koeficijenta korelacije

U nastavku je naveden skup varijabli iz baze *Airlines Customer Satisfaction*. Cilj zadatka je odrediti koje se varijable smiju koristiti s Pearsonovim koeficijentom korelacije, a koje zahtijevaju alternativne koeficijente (Spearman, Kendall, Phi, Cramer's V).

Varijabla	Tip varijable
Age	numerička (kvantitativna)
Flight Distance	numerička (kvantitativna)
Seat comfort (1–5)	ordinalna (ocjena)
Inflight entertainment (1–5)	ordinalna (ocjena)
Cleanliness (1–5)	ordinalna (ocjena)
Departure Delay in Minutes	numerička (kvantitativna)
Gender	nominalna (M/F)
Customer Type	nominalna (Loyal/Disloyal)
Type of Travel	nominalna (Business/Personal)
Class	nominalna (tri kategorije)
Satisfaction	nominalna (zadovoljan/nezadovoljan)

6.3.1 1. Varijable prikladne za Pearsonovu korelaciju

Pearsonov koeficijent koristi se za ispitivanje linearne povezanosti između **kvantitativnih varijabli** (intervalne ili omjerne skale). Primjeri varijabli koje se mogu koristiti:

- Age,
- Flight Distance,
- Departure Delay in Minutes,
- Arrival Delay in Minutes (ako postoji u odabranom skupu).

Ordinalne varijable na skali 1–5 ponekad se koriste s Pearsonom kao aproksimacija numeričke skale, ali teoretski su prikladnije za Spearmanov koeficijent (vidi iduću sekciju).

6.3.2 2. Varijable prikladne za Spearmanov ili Kendallov koeficijent

Spearmanov ρ i Kendallov τ koriste se za:

- ordinalne varijable (rangovi),
- distribucije koje ne prate normalnu razdiobu,
- monotone, ali ne nužno linearne odnose.

Za ove varijable prikladniji je Spearman ili Kendall:

- Seat comfort,
- Inflight entertainment,
- Cleanliness,
- On-board service,
- sve ostale ocjene usluge (1–5).

6.3.3 3. Varijable koje zahtijevaju nominalne koeficijente

Nominalne varijable nemaju prirodan poredak te se ne smiju analizirati Pearsonovim koeficijentom. Umjesto njega koriste se:

- **Phi koeficijent** — kada su obje varijable binarne (0/1),
- **Cramer's V** — za nominalne varijable s dvije ili više kategorija.

Primjeri varijabli koje zahtijevaju nominalne koeficijente:

- Gender (M/F),
- Customer Type,
- Type of Travel,
- Class,
- Satisfaction (ako je kategorijska, prije binarizacije).

Zadatak za pripremu:

1. Razvrstajte sve navedene varijable u tri skupine:
 - (a) varijable za Pearson,
 - (b) varijable za Spearman/Kendall,
 - (c) varijable za Phi/Cramer's V.
2. Izračunajte Pearsonovu korelaciju samo za skup kvantitativnih varijabli koje ste odabrali i komentirajte dobivenu matricu korelacije.
3. Izračunajte Spearman/Kendall korelaciju za skup ordinalnih varijabli koje ste odabrali i komentirajte dobivenu matricu korelacije
4. Odaberite dvije nominalne varijable i izračunajte Phi ili Cramer's V Protumačite dobivenu vrijednost.

6.4 Zadatak: Koeficijenti korelacije

1. Izračunajte **Pearsonovu korelacijsku matricu**, primjer koda je sljedeći:

```
corr_pearson = df[cols_pearson].corr(method="pearson")
print(corr_pearson)
```

- (a) Vizualizirajte matricu korelacije pomoću `seaborn.heatmap`.
- (b) Identificirajte:
 - dvije varijable s najjačom pozitivnom korelacijom,
 - dvije varijable s najjačom negativnom korelacijom,
 - koje varijable su najjače povezane s varijablom `Satisfied`.
- (c) Komentirajte dobivene rezultate: npr. ima li smisla da kvaliteta sjedala ili čistoća budu povezane s zadovoljstvom putnika.

2. Izračunajte **Spearmanovu korelaciju matricu**, primjer koda je sljedeći:

```
corr_spearman = df[cols_spearman].corr(method="spearman")
print(corr_spearman)
```

- (a) prvo odabrati barem pet ordinalnih varijabli (ocjena usluge).
- (b) Vizualizirajte matricu korelacije pomoću `seaborn.heatmap`

```
import seaborn as sns
import matplotlib.pyplot as plt

plt.figure(figsize=(10, 8))
sns.heatmap(corr_spearman, annot=True,
            cmap="coolwarm", fmt=".2f")
plt.title("Spearmanova korelacijska matrica")
plt.show()
```

(c) Na temelju dobivene matrice i vizualizacije:

- Identificirajte parove varijabli s **najvišom pozitivnom** korelacijom.
- Identificirajte varijable s **najslabijom** ili **negativnom** korelacijom.
- Komentirajte imaju li rezultati smisla (npr. očekivano je da su *Seat comfort* i *Leg room service* snažno pozitivno korelirani).

3. Izračunajte **Phi koeficijent** za par binarnih varijabli. Primjer koda je sljedeći:

```
from scipy.stats import chi2_contingency
import numpy as np

cont = pd.crosstab(df[var1], df[var2])
chi2, p, dof, exp = chi2_contingency(cont)
phi = np.sqrt(chi2 / df.shape[0])
print("Phi koeficijent =", phi)
```

(a) Najprije odaberite dvije **binarne varijable**, npr.:

- *Male* (1 = muškarac, 0 = žena),
- *Satisfied* (1 = zadovoljan, 0 = nezadovoljan),
- *BusinessTravel* (1 = poslovno putovanje, 0 = osobno).

(b) Kreirajte kontingencijsku tablicu za odabrane varijable:

```
cont = pd.crosstab(df[var1], df[var2])
print(cont)
```

(c) Izračunajte Phi koeficijent prema prikazanom kodu.

(d) Na temelju dobivene vrijednosti Phi koeficijenta:

- Identificirajte postoji li **pozitivna**, **negativna** ili **vrlo slaba** povezanost između varijabli.
- Usporedite dobivenu vrijednost s uobičajenim interpretacijskim kriterijima:
 - 0.00–0.10: vrlo slaba povezanost,
 - 0.10–0.20: slaba povezanost,
 - 0.20–0.40: umjerena povezanost,
 - > 0.40: jaka povezanost.
- Komentirajte imaju li dobiveni rezultati smisla. Primjer: očekivano je da je *BusinessTravel* pozitivno povezan sa zadovoljstvom, jer poslovni putnici često imaju bolju uslugu.

6.4.1 Identifikacija i uklanjanje značajki s visokom multikolinearnošću

Prije izgradnje regresijskih modela potrebno je provjeriti postoje li varijable koje su međusobno snažno povezane, jer multikolinearnost može dovesti do:

- nestabilnih procjena koeficijenata,
- rasta standardnih pogrešaka,
- problema u interpretaciji modela.

Analiza se provodi u dvije faze.

(a) Izračun korelacijskih koeficijenata Na temelju gore izračunatih matrica korelacije potrebno je:

- identificirati varijable s vrlo visokom korelacijom ($|r| > 0.8$),
- procijeniti koje je varijable poželjno izostaviti ili kombinirati,
- odabrati reprezentativne značajke koje unose najviše informacije u model.

(b) Variance Inflation Factor (VIF) VIF se koristi za kvantitativno određivanje multikolinearnosti među prediktorima.

$$VIF_j = \frac{1}{1 - R_j^2}$$

gdje je R_j^2 koeficijent determinacije iz pomoćnog OLS modela u kojem se promatrana značajka regresira na sve ostale značajke.

```

1      from statsmodels.stats.outliers_influence import
        variance_inflation_factor
2      import pandas as pd
3
4      X = df[selected_features] # numericke i dummy varijable
5      X_const = sm.add_constant(X)
6
7      vif_data = pd.DataFrame()
8      vif_data["feature"] = X.columns
9      vif_data["VIF"] = [
10     variance_inflation_factor(X_const.values, i+1) # preskace
        konst., i+1
11     for i in range(len(X.columns))
12     ]
13
14     print(vif_data)

```

Vrijednosti VIF-a tumače se na sljedeći način:

- $VIF < 5$ — prihvatljiva razina multikolinearnosti,
- $5 \leq VIF < 10$ — visoka multikolinearnost, **moгуće uklanjanje varijable** - provjeriti koeficijente korelacije prije brisanja,
- $VIF \geq 10$ — vrlo visoka multikolinearnost, **uklanjanje ili transformacija varijable preporučena**.

Na temelju dane baze podataka, sređenih podataka, možemo na primjer analizirati VIF:

```
1 from statsmodels.tools import add_constant
2 from statsmodels.stats.outliers_influence import
  variance_inflation_factor
3 import numpy as np
4
5
6 df_encoded = pd.get_dummies(df, columns = ['Class', 'Type of Travel'
  ], drop_first= True)
7
8 df_encoded[["Class_Eco", "Class_Eco Plus",
9 "Type of Travel_Personal Travel"]].astype(int)
10
11 X = add_constant(df_encoded[features])
12
13 # 1) Pretvori bool u 0/1 i sve u float
14 bool_cols = X.select_dtypes(include='bool').columns
15 X[bool_cols] = X[bool_cols].astype(int)
16 X = X.astype(float)
17
18 # 2) Ukloni NaN i inf za svaki slucaj
19 X = X.replace([np.inf, -np.inf], np.nan).dropna()
20
21 # 3) VIF s indeksima i (bez i+1, jer je const unutra)
22 vif = pd.DataFrame()
23 vif["Feature"] = X.columns
24 vif["VIF"] = [variance_inflation_factor(X.values, i)
25 for i in range(X.shape[1])]
26
27 print(vif)
```

Napomena: Za pripremu za LV isprobati druge varijable.

6.4.2 Normalizacija ili standardizacija numeričkih značajki

Ako numeričke varijable koje se koriste u regresijskom modelu imaju različite raspona vrijednosti (npr. Age, Flight Distance, Delay Minutes), preporučuje se primjena standardizacije kako bi se:

- poboljšala stabilnost optimizacijskog algoritma u logističkoj regresiji,
- spriječilo da varijable s velikim rasponom dominiraju nad ostalima,
- omogućila korektna interpretacija koeficijenata.

Za standardizaciju se koristi StandardScaler:

```
1 from sklearn.preprocessing import StandardScaler
2
3 scaler = StandardScaler()
4
```

```

5     numerical = df[numeric_cols]
6     scaled = scaler.fit_transform(numerical)
7
8     df_scaled = df.copy()
9     df_scaled[numeric_cols] = scaled

```

Standardizacija transformira svaku značajku prema formuli:

$$z = \frac{x - \bar{x}}{s_x}$$

Napomena: Standardiziraju se samo:

- numeričke varijable,
- ne standardiziraju se dummy varijable (0/1),
- ne standardiziraju se već binarizirane kategorije.

6.5 Zadatak: Logistička regresija

U ovom zadatku želimo modelirati vjerojatnost da je putnik zadovoljan (`Satisfied = 1`) na temelju nekih od ocjena usluge i karakteristika leta.

1. Odaberite nekoliko prediktora, npr.:

- Seat comfort,
- Inflight entertainment,
- On-board service,
- Cleanliness,
- Flight Distance.

```

X = df[["Seat comfort",
        "Inflight entertainment",
        "On-board service",
        "Cleanliness",
        "Flight Distance"]]
y = df["Satisfied"]

```

2. Po potrebi standardizirajte numeričke prediktore (nije obavezno za ovu vježbu, ali može pomoći pri interpretaciji i numeričkoj stabilnosti).

3. Dodajte konstantu i izgradite logistički model pomoću `statsmodels`:

```

import statsmodels.api as sm

X_const = sm.add_constant(X)
logit_model = sm.Logit(y, X_const).fit()
print(logit_model.summary())

```


4. Iz sažetka modela zapišite procijenjene koeficijente $\hat{\beta}_j$, pripadne p -vrijednosti i komentirajte:
- koji prediktori su statistički značajni,
 - imaju li koeficijenti očekivani znak (npr. viša ocjena udobnosti sjedala povećava vjerojatnost zadovoljstva).
5. Izračunajte **odds ratio** za svaki koeficijent:

```
params = logit_model.params
odds_ratios = params.apply(lambda b: np.exp(b))
print(odds_ratios)
```

6. Interpretirajte barem jedan koeficijent, npr. za "Seat comfort": objasnite koliko puta se mijenjaju izgledi za zadovoljstvo pri povećanju ocjene za jednu jedinicu.

6.6 Višestruka linearna regresija

U ovom zadatku potrebno je primijeniti sve korake obrade podataka i izgradnje modela višestruke linearne regresije.

Postavljanje višestruke linearne regresije

Korak 4.1: Definiranje ciljnih i ulaznih varijabli

Odaberite:

- ciljnu varijablu y (zavisna varijabla),
- skup značajki X (nezavisne varijable) koje uključuju numeričke i prethodno enkodirane kategorijske varijable.

```
1 y = df["TargetVariable"]
2 X = df[["Feature1", "Feature2", "Feature3"]]
3 X = sm.add_constant(X)
```

Korak 4.2: Izgradnja modela korištenjem statsmodels

- Importirati funkciju OLS iz biblioteke `statsmodels.api`.
- Izgraditi model i prikazati rezultate pomoću `summary()`.

```
1 import statsmodels.api as sm
2 import statsmodels.formula.api as smf
3
4 model = sm.OLS(y, X).fit()
5
```

```

6      # ili
7
8      model = smf.ols("y ~ Feature1 + Feature2 + Feature3", data=df)
          .fit()
9
10     print(model.summary())

```

5. Analiza rezultata modela

(a) Interpretacija koeficijenata

Promotrite izlaz modela i odgovorite na sljedeća pitanja:

- Koje značajke imaju najveći utjecaj na ciljnu varijablu?
- Jesu li koeficijenti statistički značajni (p-vrijednost < 0.05)?
- Ima li značajki čiji je učinak suprotan očekivanom?

(b) Kvaliteta modela

Analizirajte sljedeće mjere:

- R^2 (koeficijent determinacije) — koliki dio varijabilnosti ciljna varijabla objašnjava model?
- Rezidualni standardni error — je li model precizan?
- Statistika F-testa — ima li model kao cjelina objašnjavačku moć?

(c) Analiza reziduala

Korištenjem predviđenih vrijednosti iz modela, izračunajte reziduale:

```

1      df["pred"] = model.fittedvalues
2      df["resid"] = model.resid

```

Odgovorite:

- Postoje li prepoznatljivi obrasci u rezidualima?
- Jesu li reziduali približno simetrično raspodijeljeni oko nule?
- Ukazuju li reziduali na heteroskedastičnost?

6. Vizualizacija rezultata

(a) Stvarne naspram predviđenih vrijednosti

```

1 y_pred = model.predict(X)
2
3 plt.scatter(y, y_pred)
4 plt.xlabel("Stvarne vrijednosti (y)")
5 plt.ylabel("Predviđene vrijednosti ()")
6 plt.title("Stvarne vs. predviđene vrijednosti")
7 plt.plot([y.min(), y.max()], [y.min(), y.max()], "r--") # idealna
   dijagonala
8 plt.show()

```

(b) Vizualizacija reziduala

```

1 y_pred = model.predict(X)
2 resid = y - y_pred
3
4 plt.scatter(y_pred, resid)
5 plt.axhline(0, color="red", linestyle="--")
6 plt.xlabel("Predviđene vrijednosti ()")
7 plt.ylabel("Reziduali")
8 plt.title("Dijagnostički graf reziduala")
9 plt.show()

```

Zaključak

Odgovorite na sljedeća pitanja:

- Koji su ključni faktori koji utječu na ciljnu varijablu?
- Jesu li rezultati u skladu s očekivanjima (pozitivan/negativan utjecaj, značajnost)?
- Kako se višestruka linearna regresija može koristiti za interpretaciju odnosa među varijablama?
- Koja biste poboljšanja predložili (npr. uklanjanje značajki, transformacija varijabli, dodavanje novih prediktora, standardizacija)?

7

Sažetak zadatka za pripremu

7.1 Učitavanje i početni pregled podataka

- učitati skup podataka i prikazati osnovne informacije: broj redaka, tipovi varijabli, statistički opis,
- provjeriti postojanje nedostajućih vrijednosti i, po potrebi, ukloniti ili imputirati retke.

7.2 Priprema binarne ciljne varijable

- varijablu `satisfaction` potrebno je pretvoriti u binarni oblik, pri čemu vrijednost *satisfied* poprima vrijednost 1, a *neutral or dissatisfied* vrijednost 0,
- provjeriti ispravnost kreirane varijable (jedinstvene vrijednosti i distribucija).

7.3 Odabir numeričkih i ordinalnih varijabli

- odabrati numeričke varijable (npr. dob, udaljenost leta, kašnjenja),
- izdvojiti ordinalne varijable (ocjene usluge na skali 1–5).

7.4 Korelacijska analiza

- izračunati Pearsonovu korelaciju za numeričke varijable i interpretirati najjače pozitivne i negativne veze,
- izračunati Spearmanovu korelaciju nad ordinalnim varijablama i komentirati logičnost pronađenih odnosa,
- za odabrane binarne varijable izračunati Phi koeficijent i interpretirati jačinu povezanosti prema standardnim kriterijima.

7.5 Provjera multikolinearnosti

- pregledati korelacijsku matricu i identificirati parove varijabli s visokom međusobnom korelacijom,
- izračunati VIF (Variance Inflation Factor) za odabrane značajke,
- komentirati koje varijable imaju previsoku kolinearnost te ponuditi rješenja (uklanjanje, spajanje ili transformacija).

7.6 Priprema podataka za modele

- pretvoriti kategorijske varijable u dummy varijable (npr. one-hot encoding),
- po potrebi standardizirati numeričke varijable radi usporedbe koeficijenata.

7.7 Logistička regresija

- definirati ciljnu varijablu i odabrati prediktore,
- izgraditi logistički regresijski model,
- interpretirati koeficijente i p-vrijednosti,
- izračunati omjere izgleda (odds ratios) i objasniti njihov praktični smisao.

7.8 Višestruka linearna regresija (priprema za LV6)

- definirati ciljnu i ulazne varijable,
- izgraditi OLS model i interpretirati dobivene parametre,
- analizirati kvalitetu modela putem R^2 , prilagođenog R^2 i F-testa,
- grafički prikazati stvarne i predviđene vrijednosti te analizirati rezidualne.

7.9 Zaključak

Student mora opisati:

- koji su prediktori najvažniji,
- kakvi su odnosi među varijablama,
- kvaliteta prediktivnih modela i mogućnosti njihovog poboljšanja.

8 LV5 – Korelacija i višestruka linearna regresija

Analiza cijena nekretnina

Cilj vježbe: Studenti će analizirati dani dataset o nekretninama primjenom deskriptivne statistike, koeficijenata korelacije i višestruke linearne regresije. Naučit će odabrati značajke, postaviti i procijeniti regresijski model te interpretirati koeficijente i prikladnost modela.

Dataset: Housing.csv ([Kaggle housing-dataset](#)). Ciljna varijabla je `price`.

1. Učitavanje i pregled podataka

- Učitati dataset u Pythonu pomoću paketa `pandas`.
- Ispisati broj redaka i stupaca te kratko objasniti što predstavljaju.
- Analizirati tipove podataka po stupcima i razlikovati numeričke i kategoričke varijable.
- Provjeriti postoje li nedostajuće vrijednosti.
- Prikazati prvih nekoliko redaka dataseta i ukratko opisati sadržaj.

2. Deskriptivna analiza i korelacija

- Izračunati osnovne statistike (srednja vrijednost, medijan, standardna devijacija, min, max, kvartili) za numeričke varijable (`area`, `bedrooms`, `bathrooms`, `stories`, `parking`, `price`) i ukratko ih interpretirati.
- Nacrtati scatter dijagrame između `price` i svake numeričke varijable te komentirati uočene odnose.

- (c) Izračunati Pearsonovu korelacijsku matricu za numeričke varijable. Identificirati varijable koje imaju najveću pozitivnu korelaciju s `price` te eventualno varijable sa slabom korelacijom. Kratko interpretirati dobivene koeficijente i objasniti zašto korelacija ne podrazumijeva uzročnost.

3. Priprema podataka za višestruku regresiju

- (a) Definirati ciljnu varijablu `y = price` te početni skup ulaznih varijabli (numeričke i kategoričke).
- (b) Binarne kategoričke varijable mapirati na 0/1, a višeklasne varijable kodirati metodom one-hot (npr. `pd.get_dummies` s `drop_first=True`).
- (c) Kreirati DataFrame `data_selected` s ciljnom varijablom i svim odabranim značajkama te provjeriti da ne postoje nedostajuće vrijednosti.
- (d) Izračunati VIF (Variance Inflation Factor) za sve značajke. Identificirati značajke s visokim VIF-om i po potrebi ih ukloniti iz modela te ukratko obrazložiti izbor.

4. Postavljanje modela višestruke linearne regresije (statsmodels)

- (a) Definirati `y` kao `price`, a `X` kao matricu značajki te dodati stupac konstante.
- (b) Procijeniti model korištenjem funkcije `OLS` iz paketa `statsmodels` i ispisati sažetak rezultata (`summary()`).
- (c) Zapisati jednadžbu regresijskog modela s procijenjenim koeficijentima.
- (d) Identificirati statistički značajne varijable (p -vrijednost < 0.05) i ukratko interpretirati znak i veličinu njihovih koeficijenata.
- (e) Interpretirati vrijednosti R^2 , prilagođenog R^2 i F-statistike te procijeniti kvalitetu modela.

5. Provjera pretpostavki i vizualizacija rezultata

- (a) Izračunati predviđene vrijednosti i rezidualne modela.
- (b) Nacrtati scatter dijagram stvarnih naspram predviđenih vrijednosti ciljane varijable i komentirati dobivene rezultate.
- (c) Nacrtati graf reziduala naspram predviđenih vrijednosti i komentirati zadovoljava li se pretpostavka homoskedastičnosti.
- (d) Prikazati histogram i/ili QQ-plot reziduala i ukratko komentirati odstupanja od normalne distribucije.

6. Primjena modela i zaključak

- (a) Odabrati ili konstruirati barem jedan primjer kuće s konkretnim vrijednostima značajki te uz pomoć procijenjenog modela izračunati predviđenu cijenu. **(dodatno)**
- (b) U nekoliko rečenica zaključiti koji su ključni faktori koji utječu na cijenu nekretnine prema dobivenom modelu i može li se model dodatno poboljšati.